

Capítulo 1

Introducción

1.1. Motivación

La generación de residuos está ligada al modelo actual de desarrollo de la sociedad y constituye uno de los principales problemas ambientales a los que se enfrenta el mundo [47]. Los residuos se pueden clasificar en dos tipos: los producidos por la actividad industrial, llamados residuos industriales, y los generados por la propia actividad humana, denominados residuos urbanos.

Bien es cierto que gran parte de la contaminación y emisiones de CO₂ provienen de grandes empresas, por ejemplo en 2018 el 25 % de las emisiones en España fueron generadas por solamente diez compañías [2]; pero este TFG se centrará en los residuos urbanos, que son en aquellos sobre los que la población puede concienciarse y tomar medidas directas al respecto.

El problema de los residuos sólidos urbanos viene del incremento en los últimos años de utilización de envases sin retorno. Estos embalajes pueden ser de diferentes materiales como celulosa, vidrio, plástico o mixtos (papel plastificado, telas plastificadas, etc.) lo que complica su tratamiento, puesto que se debe llevar a cabo una selección y separación previa [12].

Una mala gestión de los residuos puede provocar impactos medioambientales irreversibles. A día de hoy ya se pueden observar muchos de estos efectos que parecía que vendrían en el futuro [32]. Podemos destacar entre ellos el incremento de las temperaturas en todo el globo, la desaparición de los glaciares, tanto los de las montañas como los de los casquetes polares [7], o la disminución en un 68 % de la población de vertebrados [3].

En España se observa no sólo el aumento de las temperaturas en todo el territorio, sino también la del Mediterráneo, además del incremento del nivel de este mismo. También la dilatación del verano unos 9 días por década, que da lugar a que actualmente contemos con 5 semanas más que a comienzos de los años ochenta. Otros efectos han sido la desaparición de más de la mitad de los glaciares españoles y los cambios en la distribución, comportamientos y alimentación de la biodiversidad, entre otros factores [2].

Pero la gestión adecuada de residuos es algo al alcance de la mano de cualquier ciudadano o ciudadana de a pie.

Mezclar materiales no sólo es contaminante porque dificulta la recuperación y reciclaje de estos; sino que además el proceso de separación de residuos también es costoso y contaminante, y no siempre tiene resultados satisfactorios. Esto es debido a que muchas veces los materiales recuperados, al haberse juntado con otros, son de baja calidad y con un alto nivel de partículas no reciclables. Por eso, para facilitar este proceso encontramos contenedores especiales para los distintos residuos.

Separar los desechos de manera adecuada es una gran aportación al cuidado del medioambiente, pero como se ha comentado anteriormente, hay una gran cantidad de materiales y residuos diferentes y en ocasiones puede resultar difícil y confuso cómo deben separarse. Debido a esta dificultad surge la motivación de realizar este Trabajo de Fin de Grado. Para esto se ha querido plantear y desarrollar una aplicación de identificación de objetos que utilizando la cámara de un teléfono móvil indique la manera adecuada de desechar el residuo identificado. De esta forma, sería sencillo solventar de manera cómoda para el ciudadano las dudas que puedan surgir, fomentando así el reciclaje.

1.2. Objetivos

El objetivo principal del proyecto es el desarrollo de una aplicación para dispositivos móviles de identificación de objetos enfocado al reciclaje. A través de ella los usuarios podrán identificar diferentes residuos con el fin de solventar de manera fácil y rápida las dudas sobre cómo desecharlos correctamente, ya que la aplicación dará información sobre el material y cuál es la manera adecuada de reciclarlos.

Para conseguir su correcto funcionamiento es necesario utilizar técnicas de visión artificial, que actualmente suponen el uso de redes neuronales entrenadas. Para ello, es necesario disponer de un amplio número de imágenes de residuos etiquetadas correctamente (conocido como *dataset*) que se utilice para “enseñar” (entrenar) a la red neuronal. Conseguir dicho *dataset* se convierte en uno de los principales subobjetivos del proyecto. Con el fin de facilitar el proceso de obtención de las imágenes, surge una segunda aplicación a desarrollar. El objetivo de esta es tener una alternativa que evite el proceso tedioso y lento que puede resultar la obtención de las imágenes. Se trata de una aplicación para ordenador de generación de imágenes sintéticas a partir de modelos tridimensionales. Esta aplicación genera a partir de los modelos disponibles una serie de imágenes de cada uno hasta obtener la cantidad deseada para el entrenamiento de la red neuronal.

1.3. Herramientas utilizadas

Para comenzar, se ha utilizado Android Studio para la creación de la aplicación de identificación de objetos. Para entrenar y obtener el modelo necesario para su correcto funcionamiento se ha creado un *script* en Python utilizando las librerías de Numpy y Tensorflow; como editor se ha utilizado PyScripter. Toda esta primera parte se ha basado en los ejemplos disponibles sobre Tensorflow Lite que se pueden encontrar en el blog de Tensorflow.

Para desarrollar la aplicación de generación de imágenes se ha utilizado el motor de videojuegos Unity. Los modelos que se utilizan en esta aplicación han sido conseguidos desde varios orígenes tales como Unity Asset Store, Free3D, CGTrader y 3DModelHaven.

Por último, se ha usado GitHub como plataforma para el control de versiones y TexMaker para el desarrollo de la memoria a partir de la plantilla \LaTeX .

Todo el proceso se ha realizado desde un dispositivo Windows y para las pruebas en teléfono móvil se ha usado uno con sistema operativo Android.

1.4. Plan de trabajo

El trabajo se divide en tres partes: la generación de imágenes, el entrenamiento de la red neuronal y el desarrollo de la aplicación de identificación de objetos.

La primera parte consiste en el desarrollo de una aplicación que cargue modelos 3D, separados por material, y realice numerosas imágenes a cada uno cambiándoles la posición, la rotación y el fondo para obtener diversidad en las imágenes. Estas imágenes deberán ser guardadas separadas por el material al que corresponden, igual que lo estaban los modelos al cargarlos. Para el desarrollo de la aplicación será necesario obtener una serie de modelos tridimensionales para comprobar el funcionamiento durante el proceso. Una vez todas las funcionalidades estén completadas correctamente, se procederá a ampliar la cantidad de modelos 3D y materiales para la generación del *dataset* de imágenes.

Con las imágenes generadas del paso anterior tiene lugar el entrenamiento de la red neuronal, la segunda parte del proyecto. Para llevar a cabo esto se deberá investigar sobre los distintos tipos de redes neuronales y elegir la opción más adecuada para que el resultado, el modelo entrenado, sea utilizado desde una aplicación móvil. Además, se requerirá obtener algunos *datasets* de imágenes reales de los materiales para poder realizar pruebas y comparaciones sobre la precisión de la red en distintos casos.

Por último, como se ha mencionado antes, queda el desarrollo de la aplicación para dispositivos móviles que, haciendo uso de la cámara y el modelo entrenado, identifique el material del objeto al que se está enfocando y des-

pués indique al usuario cómo se debe reciclar dicho material. En este punto del proceso también deben llevarse a cabo diversas pruebas para comprobar el funcionamiento de la aplicación. Para ello se comparará la actividad de la aplicación respecto a diferentes objetos cotidianos con el objetivo de estudiar el rendimiento de la aplicación en cada caso. Esto, además, se realizará con varios de los modelos entrenados previamente para observar la diferencia en el comportamiento de cada caso.

Bibliografía

- [1] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattemberg, M. Wicke, Y. Yu, and X. Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. Software available from tensorflow.org.
- [2] C. Alfonso, R. Estévez Estévez, J. M. Lobo, B. Lozano Diéguez, F. Prieto, J. Santamarta, and A. Gaerter. Emergencia climática en España. Diciembre 2016.
- [3] R. Almond, G. M., and T. Petersen. Wwf (2020) living planet report 2020 - bending the curve of biodiversity loss. *World Wildlife Fund (WWF)*, 2020.
- [4] Y. Amit. *2D Object Detection and Recognition: Models, Algorithms, and Networks*. Mit Press. MIT Press, 2002.
- [5] Y. Amit, P. Felzenszwalb, and R. Girshick. *Object Detection*. Springer International Publishing, Cham, 2020.
- [6] X. Basogain Olabe. Redes neuronales artificiales y sus aplicaciones. *Dpto. Ingeniería de Sistemas y Automática, Escuela Superior de Ingeniería Bilbao. Open Course Ware.*[En línea] disponible en http://ocw.ehu.es/enseñanzas-tecnicas/redes-neuronales-artificiales-y-sus-aplicaciones/Course_listing. [Consultada 20-09-2012], 2008.
- [7] M. Caballero, S. Lozano, and B. Ortega. Efecto invernadero, calentamiento global y cambio climático: una perspectiva desde las ciencias de la tierra. *Revista digital universitaria*, 8, 2007.
- [8] J. Cohen, C. F. Crispim-Junior, C. Grange-Faivre, and L. Tougne. CAD-based Learning for Egocentric Object Detection in Industrial Context.

- In *15th International Conference on Computer Vision Theory and Applications*, volume 5, Valletta, Malta, Feb. 2020. SCITEPRESS - Science and Technology Publications.
- [9] G. Cortina Fernández. Técnicas inteligentes para su integración en un vehículo autónoma. Trabajo de Fin de Grado en Ingeniería del Software, Facultad de Informática UCM, Departamento de Ingeniería del Software e Inteligencia Artificial, Curso 2019/2020., 2020.
 - [10] B. Cyganek. *Object Detection and Recognition in Digital Images: Theory and Practice*. Wiley, 2013.
 - [11] R. Flórez López, J. M. Fernández, and J. M. Fernández Fernández. *Las Redes Neuronales Artificiales*. Metodología y Análisis de Datos en Ciencias Sociales. Netbiblo, 2008.
 - [12] R. Fonfría, R. Sans, and J. de Pablo Ribas. *Ingeniería ambiental: contaminación y tratamientos*. Colección productiva. Marcombo, 1989.
 - [13] S. Frintrop. *VOCUS: A visual attention system for object detection and goal-directed search*, volume 3899. Springer, 2006.
 - [14] L. García Rodríguez. *Algunas cuestiones notables sobre el modelo de Hopfield en optimización*. PhD thesis, Madrid, Noviembre 2018. Tesis de la Universidad Complutense de Madrid, Facultad de Ciencias Matemáticas, Departamento de Estadística e Investigación Operativa, leída el 15-12-2017.
 - [15] G. A. Gómez Rojas, J. C. Henao López, and H. Salazar Isaza. Entrenamiento de una red neuronal artificial usando el algoritmo simulated annealing. *Scientia Et Technica*, 2004.
 - [16] G. Guridi Mateos et al. Modelos de redes neuronales recurrentes en clasificación de patentes. B.S. thesis, 2017.
 - [17] J. R. Hilera and V. J. Martínez Hernando. *Redes neuronales artificiales: fundamentos, modelos y aplicaciones*. 01 1995.
 - [18] S. Hinterstoisser, S. Benhimane, V. Lepetit, P. Fua, and N. Navab. Simultaneous recognition and homography extraction of local patches with a simple linear classifier. In *Proceedings of the British Machine Vision Conference*. BMVA Press, 2008. doi:10.5244/C.22.10.
 - [19] J. J. Hopfield. Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the National Academy of Sciences*, 79(8):2554–2558, 1982.

- [20] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. We-
yand, M. Andreetto, and H. Adam. Mobilenets: Efficient convolutional
neural networks for mobile vision applications, 2017.
- [21] F. N. Iandola, S. Han, M. W. Moskewicz, K. Ashraf, W. J. Dally, and
K. Keutzer. Squeezenet: Alexnet-level accuracy with 50x fewer param-
eters and <0.5mb model size, 2016.
- [22] A. Iguarán Guerra, S. Gómez Ruíz, et al. Análisis de las necesidades y
dificultades en la disposición de residuos sólidos en la fuente doméstica
para el desarrollo de un producto. B.S. thesis, Universidad EAFIT,
2010.
- [23] Y.-C. Jhang, A. Palmar, B. Li, S. Dhakad, S. K. Vishwakarma, J. Ho-
gins, A. Crespi, C. Kerr, S. Chockalingam, C. Romero, A. Thaman,
and S. Ganguly. Training a performant object detection ML model on
synthetic data using Unity Perception tools, Sep 2020.
- [24] R. Karim. *TensorFlow: Powerful Predictive Analytics with TensorFlow*.
Packt Publishing, Limited, 2018.
- [25] A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification
with deep convolutional neural networks. *Advances in neural informa-
tion processing systems*, 25, 2012.
- [26] P. Larranaga, I. Inza, and A. Moujahid. Tema 8. redes neuronales. *Redes
Neuronales, U. del P. Vasco*, 12, 1997.
- [27] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays,
P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár. Microsoft coco:
Common objects in context, 2015.
- [28] P. López and J. García-Consuegra Bleda. *Informática gráfica*, volu-
me 19. Univ de Castilla La Mancha, 1999.
- [29] M. A. López Pacheco. Identificación de sistemas no lineales con redes
neuronales convolucionales. *Cuidad de Mexico: Centro de investigación
y de estudios avanzados*, 2017.
- [30] D. J. Matich. Redes neuronales: Conceptos básicos y aplicaciones. *Uni-
versidad Tecnológica Nacional, México*, 41, 2001.
- [31] W. S. McCulloch and W. Pitts. A logical calculus of the ideas immanent
in nervous activity. *The bulletin of mathematical biophysics*, 5(4), 1943.
- [32] A. J. McMichael, D. Campbell-Lendrum, S. Kovats, S. Edwards, P. Wil-
kinson, T. Wilson, R. Nicholls, S. Hales, F. Tanser, D. L. Sueur,
M. Schlesinger, and N. Andronova. Chapter 20 global climate chan-
ge.

- [33] M. Minsky and S. A. Papert. *Perceptrons: An introduction to computational geometry*. MIT press, 2017.
- [34] S. Morant Gálvez. Desarrollo de un sistema de bajo coste para el análisis de tráfico mediante el uso de deep learning. 2021.
- [35] L. Moreno Díaz-Alejo. Análisis comparativo de arquitecturas de redes neuronales para la clasificación de imágenes. Master's thesis, 2020.
- [36] B. Müller, J. Reinhardt, and M. Strickland. *Neural Networks: An Introduction*. Physics of Neural Networks. Springer Berlin Heidelberg, 1995.
- [37] C. Parra Ramos and D. Regajo Rodríguez. Reconocimiento automático de matrículas. *Universidad Carlos III de Madrid*, 2006.
- [38] R. Pavón Benítez. Técnicas de deep learning para el reconocimiento de movimientos corporales. Trabajo de Fin de Grado en Ingeniería del Software, Facultad de Informática UCM, Departamento de Ingeniería de Software e Inteligencia Artificial, Curso 2019/2020, 2020.
- [39] A. Polacco and K. Backes. The amazon go concept: Implications, applications, and sustainability. *Journal of Business and Management*, 24(1), 2018.
- [40] A. Polacco and K. Backes. The amazon go concept: Implications, applications, and sustainability. *Journal of Business and Management*, 24(1), 2018.
- [41] G. Ros, L. Sellart, J. Materzynska, D. Vazquez, and A. M. Lopez. The synthia dataset: A large collection of synthetic images for semantic segmentation of urban scenes. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.
- [42] F. Rosenblatt. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, 65(6):386, 1958.
- [43] A. Rozantsev, V. Lepetit, and P. Fua. On rendering synthetic images for training an object detector. *Computer Vision and Image Understanding*, 137, 11 2014.
- [44] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *nature*, 323(6088), 1986.
- [45] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei. Imagenet large scale visual recognition challenge. *International journal of computer vision*, 115(3):211–252, 2015.

- [46] R. Salas. Redes neuronales artificiales. *Universidad de Valparaíso. Departamento de Computación*, 1, 2004.
- [47] M. Sánchez and J. Castro. *Gestión y Minimización de Residuos*. Fundación Confemetal, 2007.
- [48] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018.
- [49] O. Simeone. A very brief introduction to machine learning with applications to communication systems. *IEEE Transactions on Cognitive Communications and Networking*, 4(4), 2018.
- [50] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- [51] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, June 2015.
- [52] A. Terceño Ortega. Análisis de un modelo predictivo basado en google cloud y tensorflow. Trabajo de Fin de Grado en Ingeniería Informática y Matemáticas (Universidad Complutense, Facultad de Informática, curso 2016/2017), 2017.
- [53] Unity Technologies. Unity Perception package, 2020.
- [54] S.-C. Wang. *Artificial Neural Network*. Springer US, Boston, MA, 2003.
- [55] P. Warden and D. Situnayake. *TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers*. O'Reilly Media, 2019.
- [56] W. Yu and Y. Bai. Visualizing and comparing alexnet and vgg using deconvolutional layers. 2016.
- [57] J. Zamorano Ruiz et al. Comparación y análisis de métodos de clasificación con las bibliotecas scikit-learn y tensorflow en python. 2019.
- [58] J. Zurada. *Introduction to Artificial Neural Systems*. West, 1992.